

Maintenance prédictive des engins de transport de fret

Approche Machine Learning : rapport de stage (version portfolio)

Ce document est une version condensée et anonymisée du rapport de stage complet, publiée à des fins de portfolio. Les données d'entreprise réelles (historique de pannes, heures d'usage, noms de personnes, résultats individuels par engin) ont été retirées ou remplacées par des indicateurs agrégés. Le nom de l'entreprise d'accueil (ONCF) est mentionné car il s'agit d'une information publique liée au contexte du stage.

Résumé

Ce projet de stage porte sur le développement d'une solution de maintenance prédictive pour un parc d'engins de transport rail-route (TRR) utilisés sur des sites de fret. Le constat de départ est celui d'une maintenance essentiellement réactive : les interventions curatives ne surviennent qu'après la panne, sans anticipation de l'état de santé réel des engins. L'objectif a été de concevoir un modèle de machine learning capable d'estimer, pour un engin donné à une date donnée, la probabilité qu'une panne curative survienne dans un horizon de N jours à venir.

La démarche méthodologique s'est déroulée en sept étapes : nettoyage d'un historique de pannes hétérogène, construction d'une table analytique intégrant des variables d'usage, d'usure et d'historique de pannes, comparaison de plusieurs horizons de prédiction, prototypage sous KNIME, implémentation et validation croisée sous Python, puis restitution opérationnelle via un tableau de bord Power BI.

L'horizon de 14 jours a été retenu comme meilleur compromis entre performance et pertinence opérationnelle, avec un modèle XGBoost atteignant une AUC de 0,747, un rappel de 74,4% et une précision de 71,2% après optimisation du seuil de décision.

Contexte

Le secteur du transport ferroviaire de marchandises repose en grande partie sur des équipements dont la disponibilité conditionne directement la fluidité des opérations. C'est le cas d'un parc d'engins de transport rail-route (véhicules bimodaux assurant la traction et la manœuvre de wagons sur des sites de fret), dont la maintenance reposait jusqu'ici sur un mode réactif : une intervention n'a lieu qu'une fois la panne survenue, sans anticipation de l'état de santé de chaque engin.

Ce constat a motivé la question centrale du stage : à partir des données déjà collectées (historique de pannes, heures d'usage, âge des engins), est-il possible d'anticiper la survenue d'une panne curative avant qu'elle ne se produise ?

Démarche méthodologique

- Nettoyage des données : harmonisation d'un historique de pannes brut (noms d'engins, types de panne, sites), correction d'incohérences de saisie.
- Construction d'une table analytique : structuration au format engin × jour, calcul de variables explicatives (usage récent, usure cumulée, historique de pannes, âge, site, saisonnalité).
- Choix empirique de l'horizon de prédiction : comparaison de plusieurs horizons candidats (3, 7, 14, 30 jours).
- Prototypage sous KNIME, avec gestion du déséquilibre de classes et découpage entraînement/test temporel (plutôt qu'aléatoire, pour reproduire les conditions réelles d'usage).
- Implémentation et validation croisée du pipeline en Python (pandas, XGBoost).
- Construction d'un tableau de bord opérationnel sous Power BI (risque actuel, historique, usage/usure).
- Analyse critique : vérification systématique de la cohérence des résultats et identification des limites du modèle.

Résultats

Comparaison des horizons de prédiction

Horizon	AUC	Recall	Précision
3 jours	0,745	49,0%	53,7%
7 jours	0,688	45,6%	60,3%
14 jours ★	0,747	59,1%	80,0%
30 jours	0,802	85,5%	82,9%

L'horizon de 30 jours affiche statistiquement les meilleurs résultats, mais a été jugé trop large pour déclencher une action de maintenance concrète et ciblée. L'horizon de 14 jours offre le meilleur compromis entre performance et fenêtre d'action opérationnelle réaliste.

Optimisation et validation

Le seuil de décision a été optimisé par recherche systématique sur plusieurs seuils candidats, en maximisant le score F2 (favorisant le rappel sur la précision), aboutissant à un seuil final de 0,20. Le pipeline retenu a ensuite été réimplémenté indépendamment en Python, avec des résultats quasi identiques à ceux obtenus sous KNIME (écart inférieur à 1 point sur toutes les métriques), ce qui renforce la fiabilité du résultat obtenu.

Facteurs déterminants

L'analyse des contributions du modèle (feature importance) confirme que le site d'affectation de l'engin, la saisonnalité et l'historique récent de pannes sont les facteurs les plus déterminants dans la prédiction, davantage que l'âge de l'engin pris isolément.

Limites identifiées

- Volume de données limité, induisant un risque de sur-apprentissage, investigué et documenté plutôt que dissimulé.
- Couverture inégale des données d'usage selon les engins et les sites.
- Absence d'historique fiable des opérations de maintenance préventive, ayant conduit à l'abandon d'une feature pourtant pertinente sur le plan métier.
- Le modèle prédit l'occurrence d'une panne, pas sa nature : un choix de conception assumé dès le départ pour limiter le risque de sur-apprentissage sur un volume de données restreint.

Recommandations

Recommandation	Horizon	Priorité
Validation croisée par engin (leave-one-engine-out)	Court terme	Haute
Fiabilisation de la collecte de données à la source	Court terme	Haute
Utilisation régulière du tableau de bord	Court terme	Haute
Recalibrage périodique du modèle	Moyen terme	Moyenne
Modèle multi-classes du type de panne	Long terme	Basse

Conclusion

Ce projet a permis de faire évoluer une approche de maintenance d'une logique réactive vers une logique prédictive, en s'appuyant sur les données déjà disponibles. Au-delà du résultat technique, ce travail a surtout été l'occasion de mesurer combien la valeur d'un projet de data science dépend moins de la sophistication de l'algorithme employé que de la qualité du travail mené en amont sur la donnée, une donnée d'autant plus exigeante à traiter qu'elle est issue du terrain, saisie manuellement, et parfois imparfaite.

Le code source complet (nettoyage, modélisation, tableau de bord) ainsi qu'un jeu de données synthétique permettant de reproduire l'ensemble du pipeline sont disponibles dans ce dépôt.